[과제]Reservoir Sampling / DGIM Algorithm

빅데이터 최신기술

20203066 박민희

Reservoir Sampling

1.비복원 추출

```
import random
import matplotlib.pyplot as plt

arr = [0 for i in range(1000)]

class Reservoir:
    def __init__(self, k):  # 생성자 만드는거
        self.sampled = []  # sampling 한 것을 담을 리스트
        self.k = k  # 초기화
        self.cnt = 0  # 지금 들어오는 아이템이 몇번째인지

    def put(self, item):  #스트림에서 아이템하나가 들어오면 어떻게 처리할것인지
        if self.cnt < self.k:
            self.sampled.append(item)
            arr[item] += 1
        else:
            r = random.randint(0, self.cnt)
            if r < self.k:  # 랜덤으로 뽑은 r 가 k 보다 작으면
                arr[self.sampled[r]] -= 1
                self.sampled[r] = item  # sampled[r] 에다가 item 넣기
                arr[item] += 1

        self.cnt += 1

for i in range(10000):
    reservoir = Reservoir(100)  # <--요기 괄호안에 있는게 그 추출할 크기
    for j in range(1000):
        reservoir.put(j)
        #print(reservoir.sampled)
        ##0~999 까지 100 개를 10000 번

plt.plot(arr) #그래프
plt.ylim([0, 2000])
plt.show()
```

2.복원 추출

```
import random
import matplotlib.pyplot as plt

arr = [0 for i in range(1000)]

class Reservoir:

        def __init__(self, k):
                self.sampled = []
                self.k = k
                self.cnt = 0

        def put(self, item):
                if self.cnt < self.k:
                        self.sampled.append(item)
                        arr[item]+=1
                else:
                        r = random.randint(0, self.cnt)
                        if r<self.k: #랜덤으로 뽑은 r가 k보다 작으면
                                arr[self.sampled[r]]-=1
                                self.sampled[r] = item #sampled[r]에 item넣기
                                arr[item]+=1

                self.cnt +=1

for i in range(10000):
        for j in range(100):
                reservoir = Reservoir(1)
                for k in range(1000):
                        reservoir.put(k)
                        #print(reservoir.sampled)

plt.plot(arr) #그래프
plt.ylim([0, 2000])
plt.show()
```

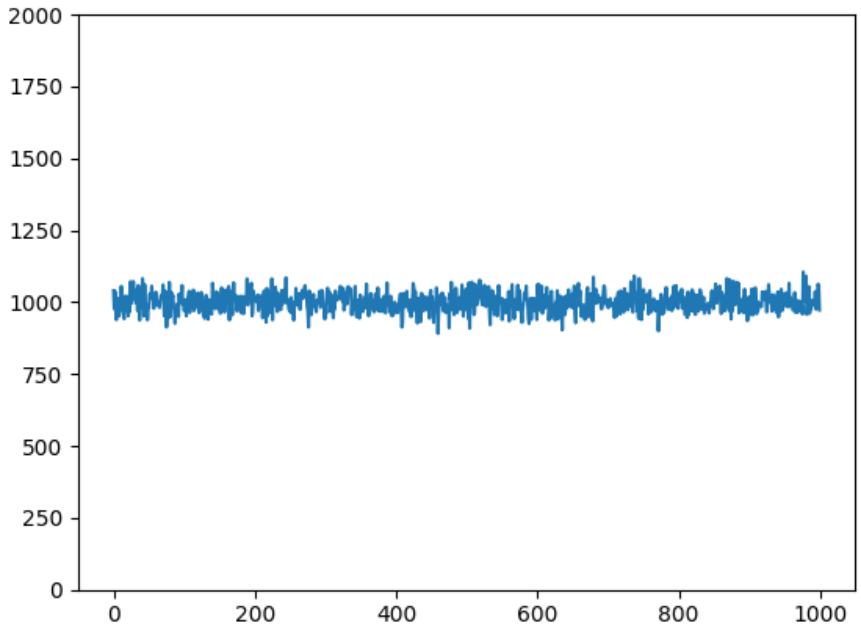

<비복원 추출>

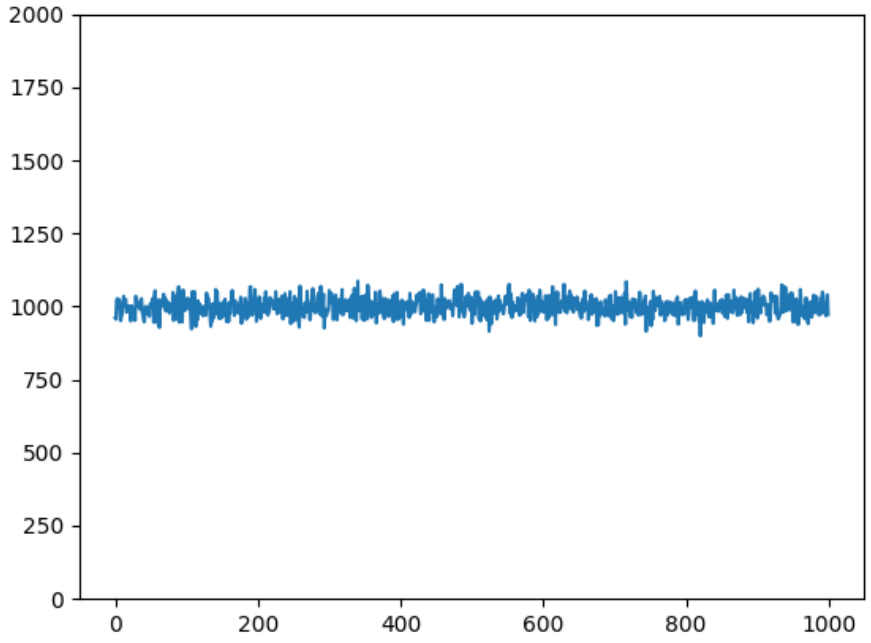

<복원 추출>

Reservoir Sampling 에서 복원 추출과 비복원 추출을 시각화 하여 그래프로 그렸을 때 각 그래프의 모든 값이 약 950 에서 1050 사이의 값으로 그려진 것으로 보인다. 1000 개의 숫자중 100 개를 뽑는 시행을 10000 회 반복하므로, 예상치는 $1000(=\frac{100}{1000} * 10000)$이였다. 복원추출과 비복원 추출 모두 그래프에서 예상치와 각 숫자가 추출된 횟수가 비슷하게 추출된 것을 확인할 수 있다.

DGIM Algorithm

```
import random
import matplotlib.pyplot as plt

class Bucket:  #박스 만드는 클래스
        def __init__(self,start,end):
                self.start = start
                self.end = end
        def __repr__(self):
                return f"({self.start},{self.end})"

class Bucket2:  #박스 만드는 클래스
        def __init__(self,start,end,psum):
                self.start = start
                self.end = end
                self.psum = psum
        def __repr__(self):
                return f"({self.start},{self.end},{self.psum})"

class DGIM:
        def __init__(self):
                self.bucket_tower = [[]]#상자들을 저장하는 공간
                self.ts =0  #timestamp

        def put(self, bit):
                if bit == 1: #1이 들어오면
                        b = Bucket(self.ts, self.ts) #노랑 박스를 만들어
                        self.bucket_tower[0].insert(0,b) #0번자리에 b를 넣어

                        layer = 0
                        while len(self.bucket_tower[layer]) >2:
                                if len(self.bucket_tower) <= layer+1:
                                        self.bucket_tower.append([])

                                b1 = self.bucket_tower[layer].pop()
                                b2 = self.bucket_tower[layer].pop()

                                b1.end = b2.end #합치기
                                self.bucket_tower[layer+1].insert(0,b1)

                                layer +=1

                self.ts +=1

# 0010100010[10101]0[101]000[1][1]0
#           s   e

        def count(self, k): #가장 최근 k개에 몇개의 1이 있었는지
                s = self.ts - k
                cnt = 0

                #검사
                for layer, buckets in enumerate(self.bucket_tower):
                        for bucket in buckets:
```

```
                                if s <= bucket.start: # 중간지점인지 아닌지
                                        cnt += (1<<layer)#중간지점이 아닌경우
                                elif s <= bucket.end: #중간지점인경우
                                        cnt += (1<<layer) * (bucket.end -s
+1)//(bucket.end - bucket.start+1)#비례하는거 계산
                                        return cnt
                                else:
                                        return cnt
                return cnt

class DGIM2:
        def __init__(self):
                self.bucket_tower = [[]]
                self.ts = 0  # timestamp

        def put(self, bit):
                #if bit == 1:  # 1 이 들어오면
                b_ = Bucket2(self.ts, self.ts,bit)  # 노랑 박스를 만들어
                self.bucket_tower[0].insert(0, b_)  # 0 번자리에 b 를 넣어

                layer = 0

                while len(self.bucket_tower[layer]) > 2:
                        if len(self.bucket_tower) <= layer + 1:
                                self.bucket_tower.append([])

                        b1 = self.bucket_tower[layer].pop()
                        b2 = self.bucket_tower[layer].pop()

                        #b1 이랑 b2 의 누적합이 2**layer 보다 작거나 같으면
                        if(b1.psum + b2.psum) <= 2**layer:
                                b1.end = b2.end  #원래대로 합쳐주고
                                b1.psum += b2.psum #누적값 바꿔주고
                                self.bucket_tower[layer + 1].insert(0, b1)
#layer+1 에 b1 넣고

                                layer += 1

                        else: #b1 이랑 b2 의 누적합이 2 의 레이어제곱보다 크다면
                                self.bucket_tower[layer + 1].insert(0, b1)
#b1 만 layer+1 에 넣고
                                self.bucket_tower[layer].insert(1,b2) #위에서
pop 했던 b2 다시 넣어주기

                                layer += 1

                self.ts += 1


        def count(self, k):
                s = self.ts - k

                cnt = 0
```

```
                #검사
                for layer, buckets in enumerate(self.bucket_tower):
                        for bucket in buckets:
                                if s <= bucket.start: #중간지점인지 아닌지
                                        cnt += bucket.psum
                                elif s <= bucket.end: #중간지점인경우
                                        cnt += bucket.psum * (bucket.end -s
+1)//(bucket.end - bucket.start+1) #비례하는거 계산
                                        return cnt
                                else:
                                        return cnt
                return cnt



dgim = DGIM()

bitstream = []

#첫번째 방법에 필요한 객체랑 배열들
a=[]
b=[]
c=[]
d=[]

dgima = DGIM()
dgimb = DGIM()
dgimc = DGIM()
dgimd = DGIM()

#요기 밑에는 스트림 랜덤으로 받는부분
for i in range(10000): #10000 개의 정수
        prob = random.randrange(16) #0~15 까지 랜덤으로 난수(정수) 생성
        bitstream.append(prob)
        a.append(((1 << 3) & prob) >> 3) #1000
        b.append(((1 << 2) & prob) >> 2) #0100
        c.append(((1 << 1) & prob) >> 1) #0010
        d.append((1 & prob))                        #0001

#첫번째 방법
#각각 비트 쪼갠거를 dgim 에 넣은거지
for i in a:
        dgima.put(i)
for i in b:
        dgimb.put(i)
for i in c:
        dgimc.put(i)
for i in d:
        dgimd.put(i)


#두번째 방법
dgim2 = DGIM2()
for i in bitstream:
        dgim2.put(i)
```

```
realsum = [] #실제합
sum1 = [] #첫번째합
sum2 = [] #두번째합

for i in range(2000):
        realsum_ = 0
        for j in range(i):
                realsum_ += bitstream[j]
        realsum.append(realsum_)

        sum1.append(dgima.count(i)*8 + dgimb.count(i)*4 + dgimc.count(i)*2 +
dgimd.count(i))

        sum2.append(dgim2.count(i))

        #print(realsum[i],sum1[i],sum2[i]) #값 출력

plt.plot(realsum,'k') #검은색
plt.plot(sum1,'b') #파랑색
plt.plot(sum2,'r') #빨간색
plt.show()
```

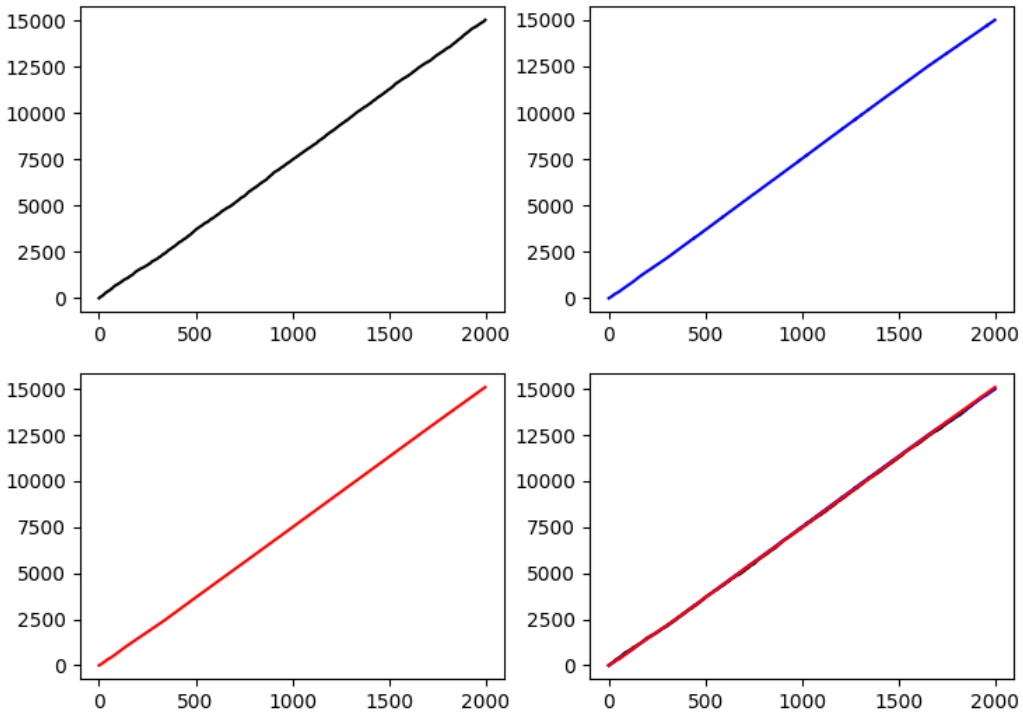

왼쪽위는 실제합, 오른쪽위는 첫번째 방법으로 구한 합,

왼쪽 아래는 두번째 방법으로 구한 합, 오른쪽 아래는 세 그래프를 합친 그래프이다.

코드는 세 그래프를 합친 그래프만 출력되게 되어있고 위의 사진은 임의로 4 개의 그래프를 보인것이다.

DGIM Algorithm 에서 실제의 합과 제시된 두가지 방법으로 구현한 합을 겹쳐보았을 때, 그래프를 확인 해보니 어떤 것이 더 정확한지는 따지기 힘들었다.

여러 번 시행하여 각 구간을 확대 해본 결과 첫번째 방법으로 구현한 합과 두번째 방법으로 구현한 합이 번갈아 가면서 실제합의 그래프와 더 가깝게 나타났기 때문이다.